

รายงานความคืบหน้าการพัฒนาแบบจำลอง

ปัญญาประดิษฐ์

โครงการ: ระบบจำแนกเสียงร้องของทารก (Baby Cry Classifier)

เอกสารอ้างอิงเริ่มต้น: เริ่ม ต้น CNN.docx

1. การทดลองครั้งที่ 1: แบบจำลองโครงสร้างผสมผสาน (CNN + LSTM)

ในการเริ่มต้นพัฒนาแบบจำลอง ได้เลือกใช้สถาปัตยกรรมแบบผสมผสานระหว่าง Convolutional Neural Network (CNN) ในการสกัดคุณลักษณะเด่นจากสัญญาณเสียง ร่วมกับ Long Short-Term Memory (LSTM) เพื่อเรียนรู้ลำดับความต่อเนื่องเชิงเวลา (Temporal Features) ของสัญญาณเสียงร้อง

ดัชนีวัดผล (Metric)	ชุดข้อมูลฝึกสอน (Training Set)	ชุดข้อมูลทดสอบ (Validation Set)
ความแม่นยำ (Accuracy)	84%	7%
ค่าความสูญเสีย (Loss)	0.49	2.51

การวิเคราะห์ปัญหา Overfitting

จากผลการทดสอบพบว่าแบบจำลองเกิดภาวะ Overfitting อย่างรุนแรง

โดยค่าความแม่นยำของชุดฝึกสอนสูงถึง 84% แต่ผลลัพธ์บนชุดข้อมูลทดสอบจริงกลับได้เพียง 7%

ภาวะนี้เกิดจากแบบจำลองทำการจดจำคุณลักษณะเฉพาะของชุดข้อมูลฝึกสอนมากเกินไป

จนไม่สามารถนำไปประยุกต์ใช้ทำนายข้อมูลชุดใหม่ในสถานการณ์จริงได้ (Generalization Failure)

สาเหตุหลัก: ปริมาณข้อมูลมีจำกัดเกินไป โดยมีข้อมูลเริ่มต้นเพียง 12 Batches $\times$ 32 = ~370 ไฟล์

เมื่อกระจายตัวไปยังคลาสเป้าหมายทั้ง 5 คลาส จะเฉลี่ยเพียงคลาสละประมาณ 74 ไฟล์

ซึ่งไม่เพียงพอต่อการปรับค่าพารามิเตอร์ในโมเดลขนาดใหญ่อย่าง CNN + LSTM

2. การทดลองครั้งที่ 2:

การขยายข้อมูลและการปรับลดขนาดโครงสร้าง (Data Augmentation & Light-weight CNN)

แนวทางการแก้ไขปัญหานี้
มุ่งเน้นไปที่การเพิ่มปริมาณชุดข้อมูลและการปรับโครงสร้างโมเดลให้มีความกระชับและซับซ้อนน้อยลง เพื่อลดโอกาสการจดจำข้อมูล


หัวข้อการปรับปรุง	รูปแบบเดิม (ครั้งที่ 1)	รูปแบบใหม่ (ครั้งที่ 2)
ปริมาณข้อมูล (Dataset Size)	~370 ไฟล์	~2,200 ไฟล์ (ผ่านกระบวนการ x6 Data Augmentation)
สถาปัตยกรรมแบบจำลอง	CNN + LSTM ขนาดใหญ่	CNN ขนาดเล็ก (Light-weight CNN)
การลดรูปมิติ (Pooling)	Max Pooling	Global Average Pooling
ขนาดการประมวลผล (Batch Size)	32	16
อัตราการสุ่มตัดการเชื่อมต่อ (Dropout)	0.2 - 0.4	0.3 - 0.5

ผลการทดสอบและการวิเคราะห์ปัญหา Class Imbalance

หลังจากการปรับปรุง แบบจำลองให้ค่าความแม่นยำบนชุดฝึกสอน (Train Accuracy) อยู่ที่ 83.6% และชุดทดสอบ (Validation Accuracy) อยู่ที่ 83.6% ซึ่งมีทิศทางที่สอดคล้องกัน อย่างไรก็ตาม เมื่อนำไปทดสอบจำแนกรายไฟล์ในระบบปฏิบัติการจริง พบข้อผิดพลาดเชิงโครงสร้างที่สำคัญคือ แบบจำลองทำนายผลลัพธ์เป็นคลาส "หิว (Hungry)" ที่ระดับความเชื่อมั่น 70% - 85% ในทุกกรณี แม้ว่าสัญญาณเสียงที่ส่งเข้ามาจะเป็นคลาสใดก็ตาม

สาเหตุหลัก: เกิดปัญหาความไม่สมดุลของข้อมูลแต่ละคลาส (Class Imbalance) ในงานประเภท Classification

ทำให้แบบจำลองเลือกที่จะพยากรณ์คลาสที่มีแนวโน้มหรือสัดส่วนทางสถิติสูงสุดเพื่อรักษาค่าความแม่นยำโดยรวม แต่ไม่สามารถแยกแยะคุณลักษณะเด่น (Features) ของคลาสอื่นได้จริง



รูปภาพแสดงผลทดสอบ


3. การทดลองครั้งที่ 3: การถ่ายโอนความรู้ผ่านเทคนิค Transfer Learning (YAMNet + Dense)

เพื่อแก้ปัญหาการสกดพีเจอร์ที่ไม่มีประสิทธิภาพ
จึงได้เปลี่ยนไปใช้โมเดลโครงข่ายประสาทเทียมสำเร็จรูประดับสากลอย่าง YAMNet ของ Google
ซึ่งถูกฝึกสอนมากับชุดข้อมูลเสียงขนาดใหญ่ (AudioSet) แล้วนำมาเชื่อมต่อเข้ากับชั้นข้อมูลหนาแน่น (Dense Layer) เพื่อจำแนกเสียงร้อง 5 คลาสหลัก

สถาปัตยกรรมแบบจำลอง	ความแม่นยำชุดฝึกสอน (Train Acc)	ความแม่นยำชุดทดสอบ (Validation Acc)
CNN เดิม (ปรับปรุงจากครั้งที่ 2)	84%	43%
YAMNet + Dense Layer	92.5%	84%

ข้อจำกัดเชิงเทคนิค

แม้การใช้เทคนิค Transfer Learning จะช่วยเพิ่มความแม่นยำรวมของชุดทดสอบขึ้นเป็น 84% และสามารถนำไปพัฒนาต่อยอดหน้าต่างแอปพลิเคชัน (User Interface) สกีนมืดเพื่อแสดงกราฟวงกลมความน่าจะเป็นได้อย่างสวยงาม
แต่มีข้อจำกัดด้านการวิจัยทางด้านปัญญาประดิษฐ์
เนื่องจากโครงสร้างหลักเป็นสถาปัตยกรรมสำเร็จรูปที่ถูกตรึงค่าน้ำหนัก (Freeze Weights) ไว้จากภายนอก
นักพัฒนาทำการฝึกสอน (Train) ได้เฉพาะในส่วนของ Dense Layer ที่ต่อท้ายเพิ่มเติมเท่านั้น
จึงไม่ถือเป็นการสร้างและฝึกสอนระบบด้วยตนเองอย่างสมบูรณ์



รูปภาพตัวอย่างApp

4. การทดลองครั้งที่ 4: ความสำเร็จด้วยสถาปัตยกรรมสร้างเอง (CNN + MFCC)

เป้าหมายสูงสุดคือการสร้างและออกแบบโมเดลขึ้นเองทั้งหมด (Scratch Model)
ในครั้งนี้จึงเปลี่ยนกระบวนการสกัดคุณลักษณะเด่นของเสียงมาใช้เทคนิค Mel-Frequency Cepstral Coefficients (MFCC)
เพื่อแปลงสัญญาณเสียงร้องให้เป็นภาพสเปกตรัมความถี่ที่มีมิติใกล้เคียงกับการได้ยินของมนุษย์
แล้วนำภาพเหล่านั้นเข้าสู่กระบวนการเรียนรู้ผ่านโครงข่ายประสาทเทียมแบบ CNN ที่ออกแบบขึ้นเอง

สถาปัตยกรรมแบบจำลอง	ความแม่นยำชุดฝึกสอน (Train Acc)	ความแม่นยำชุดทดสอบ (Validation Acc)
YAMNet + Dense (ครั้งที่ 3)	92.5%	84%
CNN + MFCC (สร้างเอง - ครั้งที่ 4)	97.16%	97.16%

บทสรุปผลการดำเนินงาน

สถาปัตยกรรมแบบ CNN + MFCC สามารถบรรลุประสิทธิภาพสูงสุดอย่างเป็นเอกฉันท์
โดยให้ค่าความแม่นยำสูงถึง 97.16% ทั้งในชุดข้อมูลฝึกสอนและชุดข้อมูลทดสอบ
อีกทั้งเมื่อนำไปทดสอบเชิงลึกรายคลาส (Per-class Evaluation)
พบว่าแบบจำลองสามารถจำแนกเสียงได้อย่างถูกต้อง แม่นยำ
และไม่มีปัญหาการเอนเอียงไปยังคลาสใดคลาสหนึ่งอีกต่อไป โดยมีสถิติดังนี้:

- เสียงร้องจากภาวะปวดท้อง (Belly Pain): ทายถูกต้องด้วยความมั่นใจ 90.7%
- เสียงร้องจากการเรอ (Burping): ทายถูกต้องด้วยความมั่นใจ 98.7%
- เสียงร้องจากความไม่สบายตัว (Discomfort): ทายถูกต้องด้วยความมั่นใจ 94.0%
- เสียงร้องจากความหิว (Hungry): ทายถูกต้องด้วยความมั่นใจ 78.2%
- เสียงร้องจากความเหนื่อยล้า/ง่วงนอน (Tired): ทายถูกต้องด้วยความมั่นใจ 91.2%

ระบบนี้ได้ถูกนำไปประยุกต์ใช้ร่วมกับแอปพลิเคชันส่วนหน้า (Baby Cry Detector) เวอร์ชันเอ็มสว่าง (Light

Mode) ซึ่งประมวลผลการคำนวณและพล็อตแผนภูมิความน่าจะเป็นแบบ Real-time

ได้อย่างสมบูรณ์และพร้อมใช้งานในขั้นต่อไป



รูปภาพแสดงผลทดสอบ

Baby Cry

Emotion Detector • CNN MFCC



ไฟล์ที่เลือก:

69BDA5D6-0276-4462-9BF7-951799563728-1436936185-1.1-m-26-bp.wav

☒ วิเคราะห์เสร็จแล้ว — คลิกเพื่อเลือกไฟล์ใหม่

ผลการวิเคราะห์



ปวดท้อง


ความมั่นใจ 90.2%

ความน่าจะเป็นทุก class

😊 ปวดท้อง		90.2%
😓 เหนื่อย		0.1%
😬 ไม่สบาย		0.7%
👄 หิว		8.8%
😓 เหนื่อย		0.1%

กราฟวงกลม

Probability Distribution



- Belly Pain 90.2%
- Burping 0.1%
- Discomfort 0.7%
- Hungry 8.8%
- Tired 0.1%

รูปภาพตัวอย่างApp